

# Metodologia Ecológica

## Abordagens e Métodos Estatísticos em Ecologia


### Aula 4

Mais ainda sobre a hipótese nula: erro tipo I e II

Poder!

# Percentis e *box plots*

- Percentis mais usados: 90, 75, 50 (mediana)
- Coeficiente de variação
- Coeficiente de dispersão



**Figura 3.6** Box plot ilustrando os quantis dos dados da Tabela 3.1 ( $n = 50$ ). A linha indica o 50° percentil (mediana) e a “caixa” engloba 50% dos dados, a partir do 25° até o 75° percentil. As linhas verticais se estendem do 10° ao 90° percentil.

# Intervalos de confiança para *média*

$$P(\text{média} - 1,96ep \leq \mu \leq \text{média} + 1,96ep) = 0,95$$

Intervalos de confiança generalizados

$$\bar{x} \pm t \cdot \frac{\sigma}{\sqrt{n}}$$

Distribuição  $t$  (de Student)


# Intervalos de confiança para *média*

$$P(-1,96 \leq Z \leq +1,96) = 0,95$$

$$\text{média} - 1,96 \text{ ep} \leq \mu \leq \text{média} + 1,96 \text{ ep}$$

$$\bar{x} \pm t \cdot \frac{\sigma}{\sqrt{n}}$$

Distribuição *t* (de Student)



**Figura 3.7** Distribuição- $t$  ilustrando que 95% das observações, ou massa de probabilidade, caem dentro do percentil de  $\pm 1,96$  desvio-padrão da média (média = 0). As duas caudas da distribuição contêm cada 2,5% das observações ou massa de probabilidade da distribuição. Elas somam 5% das observações, e a probabilidade  $P = 0,05$  de que uma observação caia nessas caudas. Esta distribuição é idêntica à distribuição- $t$  ilustrada na Figura 3.5.

# Erro Tipo I : $\alpha$

- Probabilidade de rejeitar  $H_0$  quando verdadeira
- Probabilidade de falso negativo
- Para calcular depende:  
basta especificar  $H_0$
- Teste conservador

# Testes de hipótese nula comuns

- Diferença entre médias de duas amostras:
  - Teste  $t$
  - Razão  $F$  (script de R do Michael Crawley)
  - Premissas



# Testes $t$

para testar  $H_0$  de diferença entre duas médias


$$t = \frac{\bar{X}_1 - \bar{X}_2}{S_{\bar{X}_1 - \bar{X}_2}}$$

$$S_{\bar{X}_1 - \bar{X}_2} = \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

$$t = \frac{\textit{Diferença entre médias}}{\textit{Erro padrão da diferença entre médias}}$$

# Erro Tipo II : $\beta$


- Probabilidade de não rejeitar  $H_0$  quando falsa, ou probabilidade de falso positivo,  $\beta$
- Para calcular depende:
  - Da hipótese alternativa
  - Do tamanho do efeito que se pretende detectar
  - Do tamanho da amostra
  - Do delineamento experimental
- Poder: probabilidade de rejeitar corretamente  $H_0$  quando falsa:  $1 - \beta$
- Princípio de precaução em monitoramento ambiental




**Figura 4.5** Relação entre poder estatístico, valor de  $P$  e tamanho do efeito observável em função do tamanho amostral. (A) O valor de  $P$  é a probabilidade de incorretamente rejeitar uma hipótese nula verdadeira, enquanto o poder estatístico é a probabilidade de corretamente rejeitar uma hipótese nula falsa. O resultado geral propõe que, quanto menor o valor de  $P$  usado para rejeitar a hipótese nula, menor o poder estatístico de corretamente detectar um efeito do tratamento. A um dado valor de  $P$ , o poder estatístico é maior quando o tamanho amostral é maior. (B) Quanto menor o tamanho do efeito observável do tratamento (i. e., quanto menor a diferença entre o grupo-tratamento e o grupo-controle), maior é o tamanho amostral necessário a um bom poder estatístico para detectar o efeito do tratamento.<sup>21</sup>

# Momentos da distribuição normal

- Momento centrado (*Central Moment*)
- 1o. : desvio padrão
- 2o.: variância
- 3o.: assimetria (*skewness*)
- 4o.: curtose (*kurtosis*)



**Figura 3.4** Distribuição contínua ilustrando a assimetria ( $g_1$ ). A assimetria mede a extensão na qual a distribuição é assimétrica, com uma longa cauda de probabilidades à direita ou à esquerda. A curva verde é a distribuição log-normal ilustrada na Figura 2.8; ela tem assimetria positiva, com muito mais observações à direita da média do que à esquerda (uma longa cauda à direita), e uma medida de assimetria de 6,9. A curva preta representa uma amostra de 1.000 observações de uma variável aleatória normal com média e desvio-padrão idênticos aos da distribuição log-normal. Como esses dados foram tirados de distribuições normais simétricas, eles têm aproximadamente o mesmo número de observações em cada lado da média e a assimetria medida é aproximadamente 0.



**Figura 3.5** Distribuições ilustrando curtoses ( $g_2$ ). A curtose mede a extensão na qual a distribuição é de cauda-pesada ou de cauda-leve, quando comparadas a uma distribuição normal padrão. Distribuições com caudas-pesadas são leptocúrticas e contêm relativamente mais área nas caudas da distribuição e menos no centro. Distribuições leptocúrticas possuem valores positivos para  $g_2$ . Distribuições com caudas-leves são platicúrticas e contêm relativamente menos área nas caudas da distribuição e mais no centro. Distribuições platicúrticas têm valores negativos para  $g_2$ . A curva preta representa uma amostra com 1.000 observações de uma variável aleatória normal com média 0 e desvio-padrão 1 ( $X \sim N(0,1)$ ); sua curtose é próxima de 0. A curva verde é uma amostra de 1.000 observações de uma distribuição  $t$  com 3 graus de liberdade. A distribuição  $t$  é leptocúrtica e tem curtose positiva ( $g_2 = 6,05$  neste exemplo).

# O significado de uma “variável” ser dita “aleatória”

- Definimos o espaço amostral  $\Omega = \{(\text{captura}), (\text{fuga})\}$  para os resultados possíveis dos evento visita de um inseto a uma planta carnívora.
- Para analisar estatisticamente esta informação, precisamos associar a cada elemento do espaço amostral um número.
- Precisamos de uma **função** que atribua um valor a cada elemento do espaço amostral.
- A esta função é dado o nome **variável aleatória**, normalmente representada por letras maiúsculas, como  $X$ .

# Variáveis aleatórias

- Assim a variável aleatória na verdade é uma função cujos valores não são aleatórios (!?).
- É dita “aleatória” porque os valores de  $X$  dependem do resultado do experimento, que tem um grau de incerteza nos resultados, de “aleatoriedade”.
- Uma variável associa a cada valor possível uma certa probabilidade.



# Tipos de variáveis aleatórias

- Variáveis aleatórias podem ser discretas ou contínuas.
  - Variáveis aleatórias discretas têm um número finito de valores dentro de um intervalo.
    - Exemplos:  $X \sim \text{Bin}(n, p)$
  - Variáveis aleatórias contínuas podem ter um número infinito de valores dentro de um intervalo.
    - Exemplos

# Tipos de variáveis aleatórias

- Variáveis aleatórias podem ser discretas ou contínuas.
  - Variáveis aleatórias discretas têm um número finito de valores dentro de um intervalo.
    - Exemplos:  $X \sim \text{Bin}(n, p)$
    - $X \sim \text{Poisson}(\lambda)$
  - Variáveis aleatórias contínuas podem ter um número infinito de valores dentro de um intervalo.

- Exemplos


# Variáveis aleatórias discretas

- $X \sim \text{Bin}(n, p)$        $P(X) = \frac{n!}{X!(n-X)!} p^X (1-p)^{n-X}$

- $X \sim \text{Poisson}(\lambda)$        $P(x) = \frac{\lambda^x}{x!} e^{-\lambda}$


$$P(4 \text{ plântulas}) = \frac{0,75^4}{4!} e^{-0,75} = 0,0062$$

# Variáveis aleatórias contínuas



**Figura 2.4** Distribuição uniforme com intervalo  $[0,10]$ . Em uma distribuição uniforme contínua, a probabilidade de um evento ocorrer em um subintervalo particular depende da área relativa do subintervalo; ela é a mesma independente de onde o subintervalo está inserido dentro dos limites da distribuição. Por exemplo, se a distribuição é delimitada por 0 e 10, a probabilidade de que um evento ocorra no subintervalo  $[3,4]$  é a área relativa delimitada por aquele subintervalo, que neste caso é 0,10. A probabilidade é a mesma para qualquer outro subintervalo com o mesmo tamanho, como  $[1,2]$  ou  $[4,5]$ . Se o subintervalo escolhido é maior, a probabilidade de um evento ocorrer naquele subintervalo será proporcionalmente maior. Por exemplo, a probabilidade de um evento ocorrer no subintervalo  $[3,5]$  é de 0,20 (desde que 2 dentre as 10 unidades do intervalo sejam transpassadas), e é de 0,6 para o subintervalo  $[2,8]$ .

# Variáveis aleatórias contínuas



**Figura 2.8** Distribuições log-normal e exponencial se ajustam a certos tipos de dados ecológicos, como a distribuição de abundâncias de espécies e distâncias de dispersão de sementes. (A) A distribuição log-normal é descrita por dois parâmetros, média e variância, ambos são 1 neste exemplo. (B) A distribuição exponencial é descrita por um único parâmetro  $b$ , que é 2 nesse exemplo. Ver a Tabela 2.4 para as equações usadas com as distribuições log-normal e exponencial. Ambas as distribuições, log-normal e exponencial, são assimétricas, com uma longa cauda a direita que desvia a distribuição à direita.

# Estimativas

- Em estatística frequentista (ou assintótica)
  - Parâmetros na população são fixos
  - Amostrando-se a população repetidamente, infinitamente, a estimativa dos parâmetros irá convergir (na assíntota) nos valores reais dos parâmetros
- É uma premissa realista?